# NVIDIA CUDA И OPENACC
# ЛЕКЦИЯ 2

Перепёлкин Евгений

# СОДЕРЖАНИЕ

## Лекция 2

- Программная модель CUDA
- Гибридная модель программного кода
- Понятие потока, блока, сети блоков
- Функция-ядро как параллельный код на GPU
- Пример программы на CUDA

# *Программная модель CUDA*

# ПРОГРАММИРОВАНИЕ НА GPU

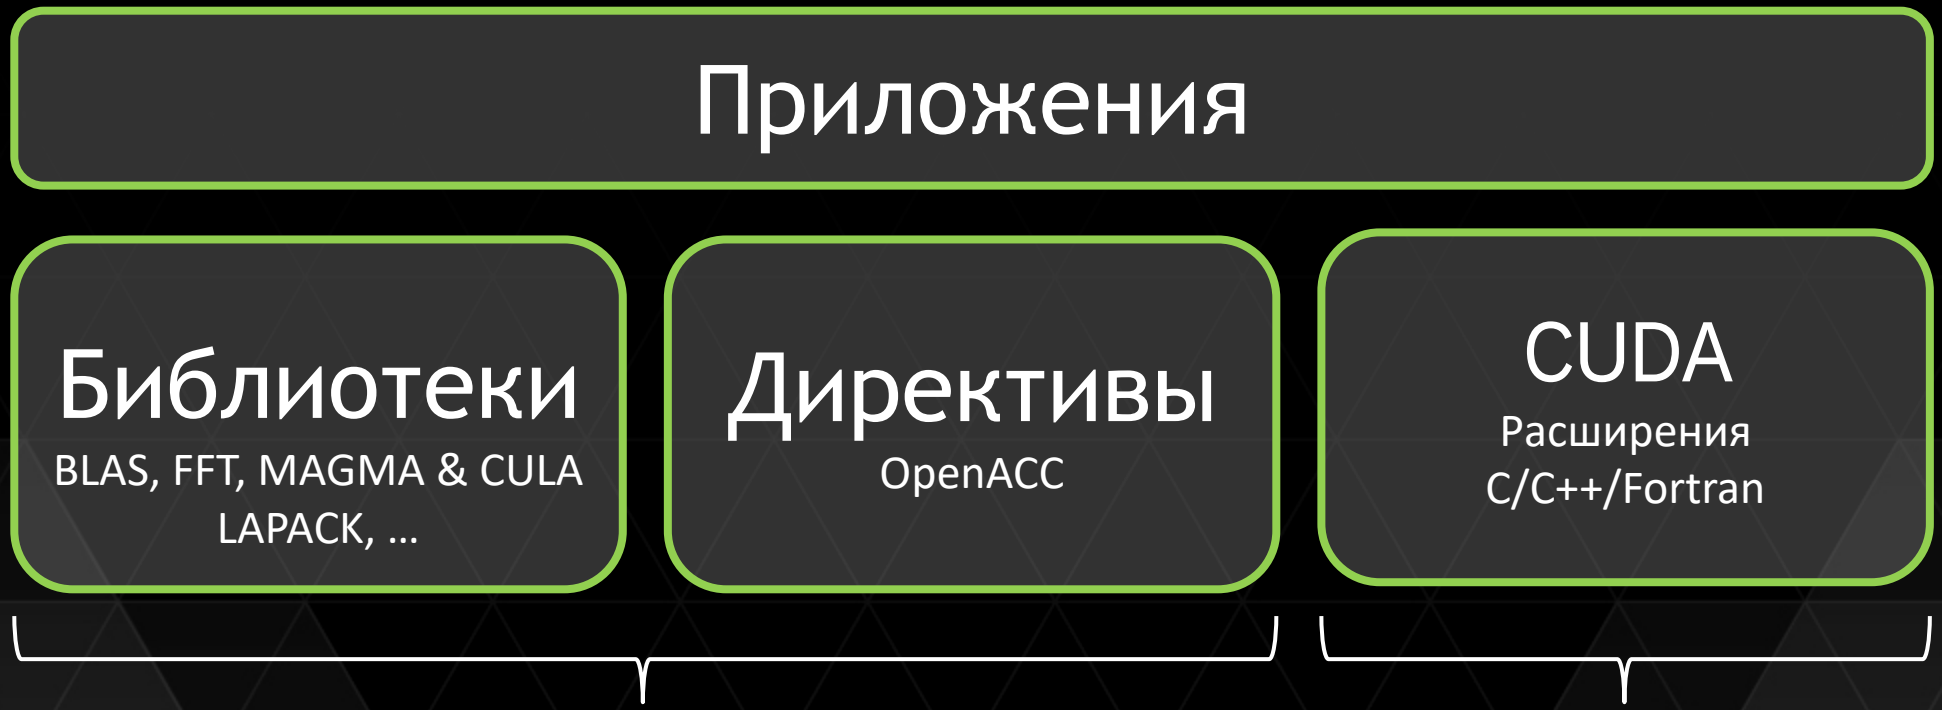

# ПЕРВЫЙ ШАГ

## Библиотеки

- cuFFT ( Быстрое Преобразование Фурье )
- cuBLAS ( библиотека линейной алгебры )
- cuRAND ( генератор случайных чисел )
- cuSPARSE ( работа с разряженными матрицами )
- cuDNN ( нейросети, Deep Learning )
- cuSolver ( поиск собственных значений )
- NPP ( библиотека примитивов )
- Plugin - MATLAB, Mathematica

# ВТОРОЙ ШАГ

## OpenACC

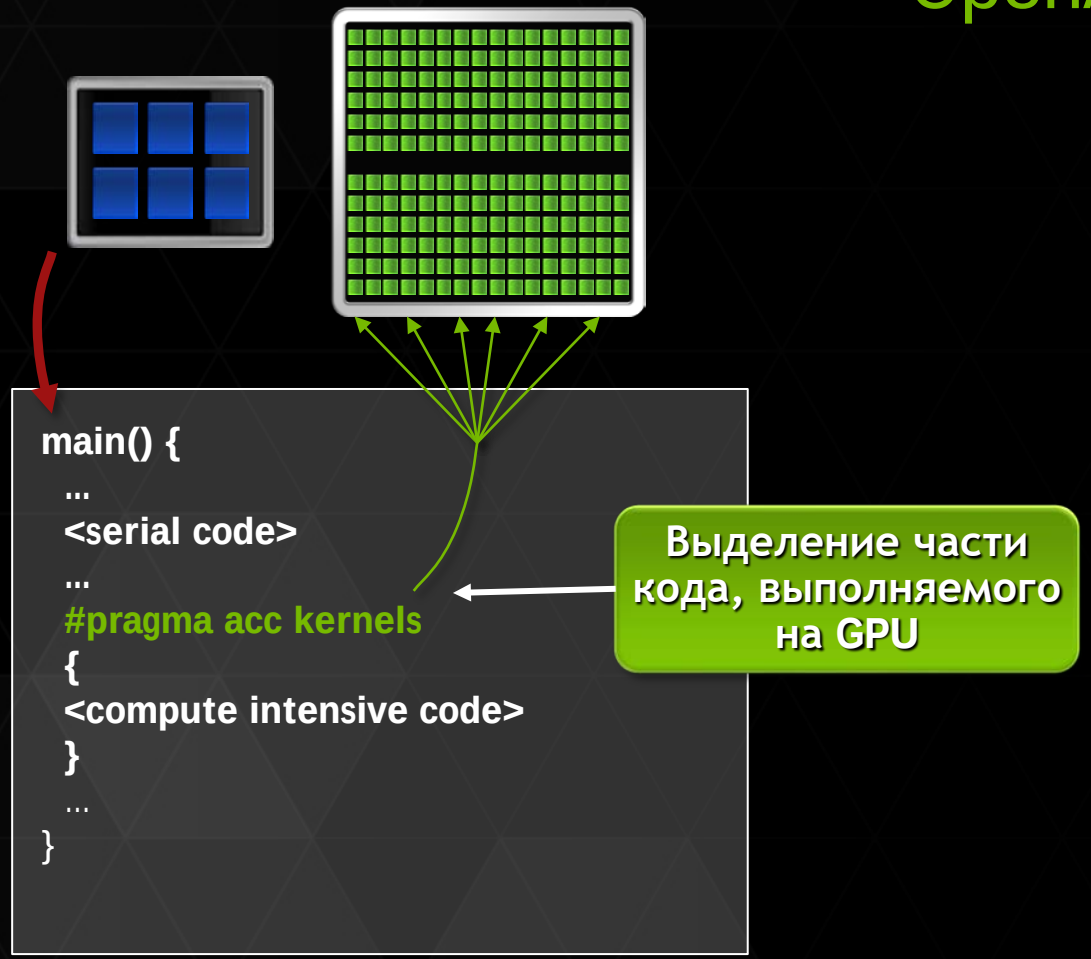


- Открытый стандарт
- Простота
- Использование на GPUs

# ТРЕТИЙ ШАГ

## Compute Unified Device Architecture

**GPU Computing Applications**

**Libraries and Middleware**

| | | | | | | |
|---|---|---|---|---|---|---|
| cuFFT<br>cuBLAS<br>cuRAND<br>cuSPARSE | CULA<br>MAGMA | Thrust<br>NPP | VSIPL<br>SVM<br>OpenCurrent | PhysX<br>OptiX<br>iRay | cuDNN<br>TensorRT | MATLAB<br>Mathematica |

**Programming Languages**

| | | | | | |
|---|---|---|---|---|---|
| C | C++ | Fortran | DirectCompute | Java<br>Python<br>Wrappers | Directives<br>(e.g. OpenACC) |

**NVIDIA GPU**
CUDA Parallel Computing Architecture

# С ЧЕГО НАЧАТЬ?

http://developer.nvidia.com

- Драйвер для видеокарты «NVIDIA»
- CUDA SDK
- CUDA ToolKit
- Parallel Nsight + MS VS
- Документация по CUDA

# *Гибридная модель программного кода*

# СТРУКТУРА КОДА

Последовательный код

Параллельное ядро A

```
KernelA <<< nBlk, nTid >>> (args);
```

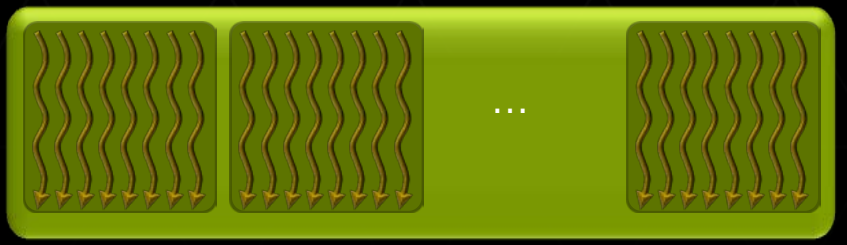


Последовательный код

Параллельное ядро B

```
KernelB <<< nBlk, nTid >>> (args);
```

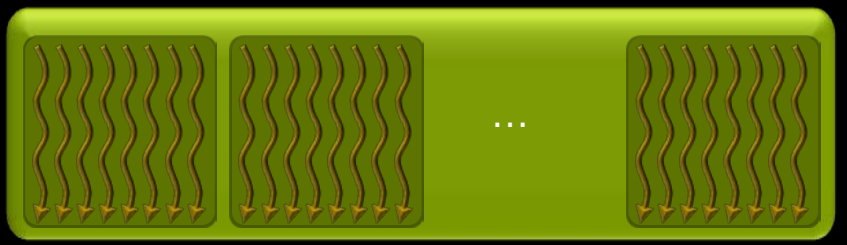

# СБОРКА ПРИЛОЖЕНИЯ

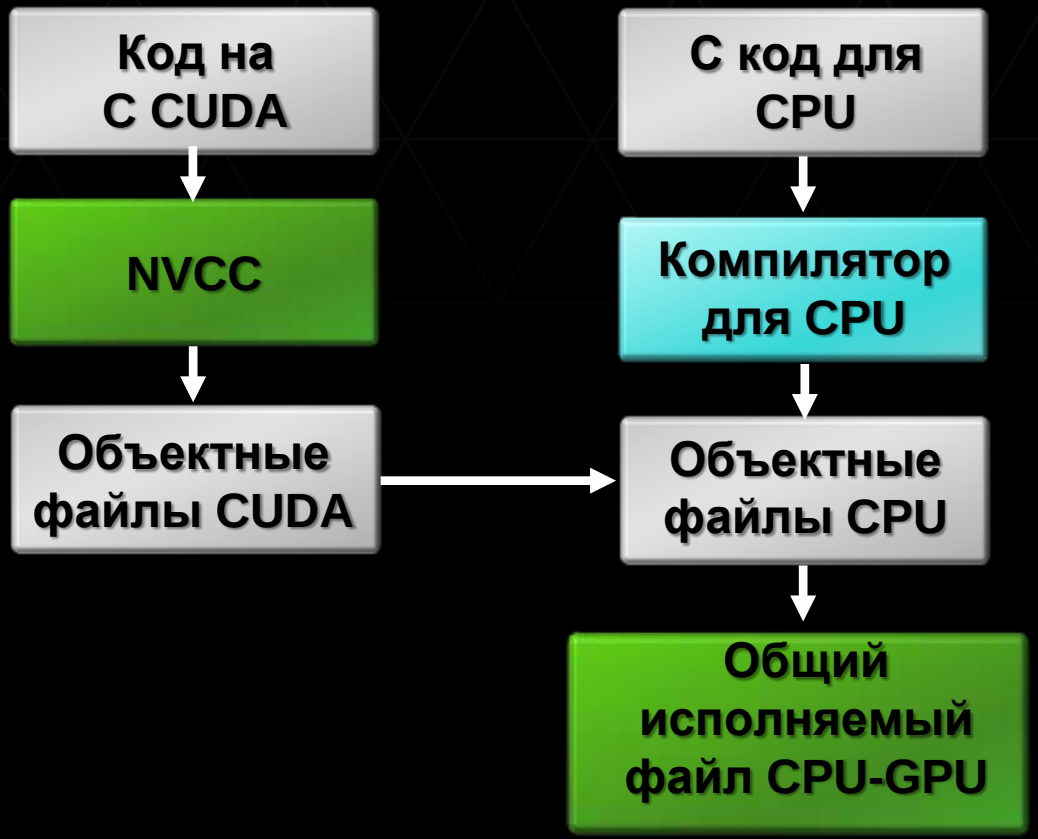

# ОСНОВНЫЕ ПОНЯТИЯ

- «host» - x86, ARM
- «device» - GPU

```
Kernel <<< nBlk, nTid >>> (args);
```

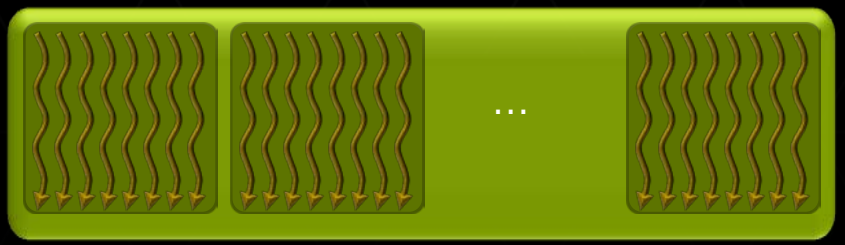


$N_{max}$ – максимальное число потоков на GPU

$$y_i = f(x_i), i = 1, \dots, N$$

$N \leq N_{max}$ или $N > N_{max}$

# *Понятие потока, блока, сети блоков*

# ПОТОКИ И БЛОКИ ПОТОКОВ

```
Kernel <<< nBlk, nTid >>> (args);
```

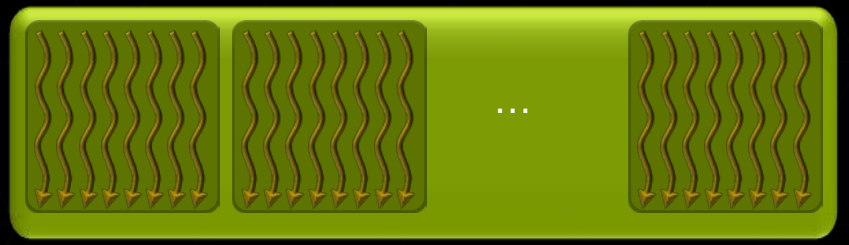


```
nBlk = N / nTid
```

или

```
nBlk = ( int ) ( N / nTid ) + 1
```

**Warp** состоит из 32 потоков

# ПОТОКИ И БЛОКИ ПОТОКОВ

```
dim3 grid (10,1,1);
dim3 block (16,16,1);
My_kernel <<< grid, block >>> ( param );
```

или

```
dim3 grid (10);
dim3 block (16,16);
```

# ПОТОКИ И БЛОКИ ПОТОКОВ

threadIdx – номер нити в блоке
blockIdx – номер блока, в котором находится нить
blockDim – размер блока

Глобальный номер нити внутри сети:

```
threadID = threadIdx.x + blockIdx.x * blockDim.x
```

В общем (3D) случае:

```
threadIdx – { threadIdx.x, threadIdx.y, threadIdx.z }
blockIdx  – { blockIdx.x, blockIdx.y, blockdx.z }
blockDim  – { blockDim.x, blockDim.y, blockDim.z }
```

# ПОТОКИ И БЛОКИ ПОТОКОВ

## Запуск блоков на различных GPU

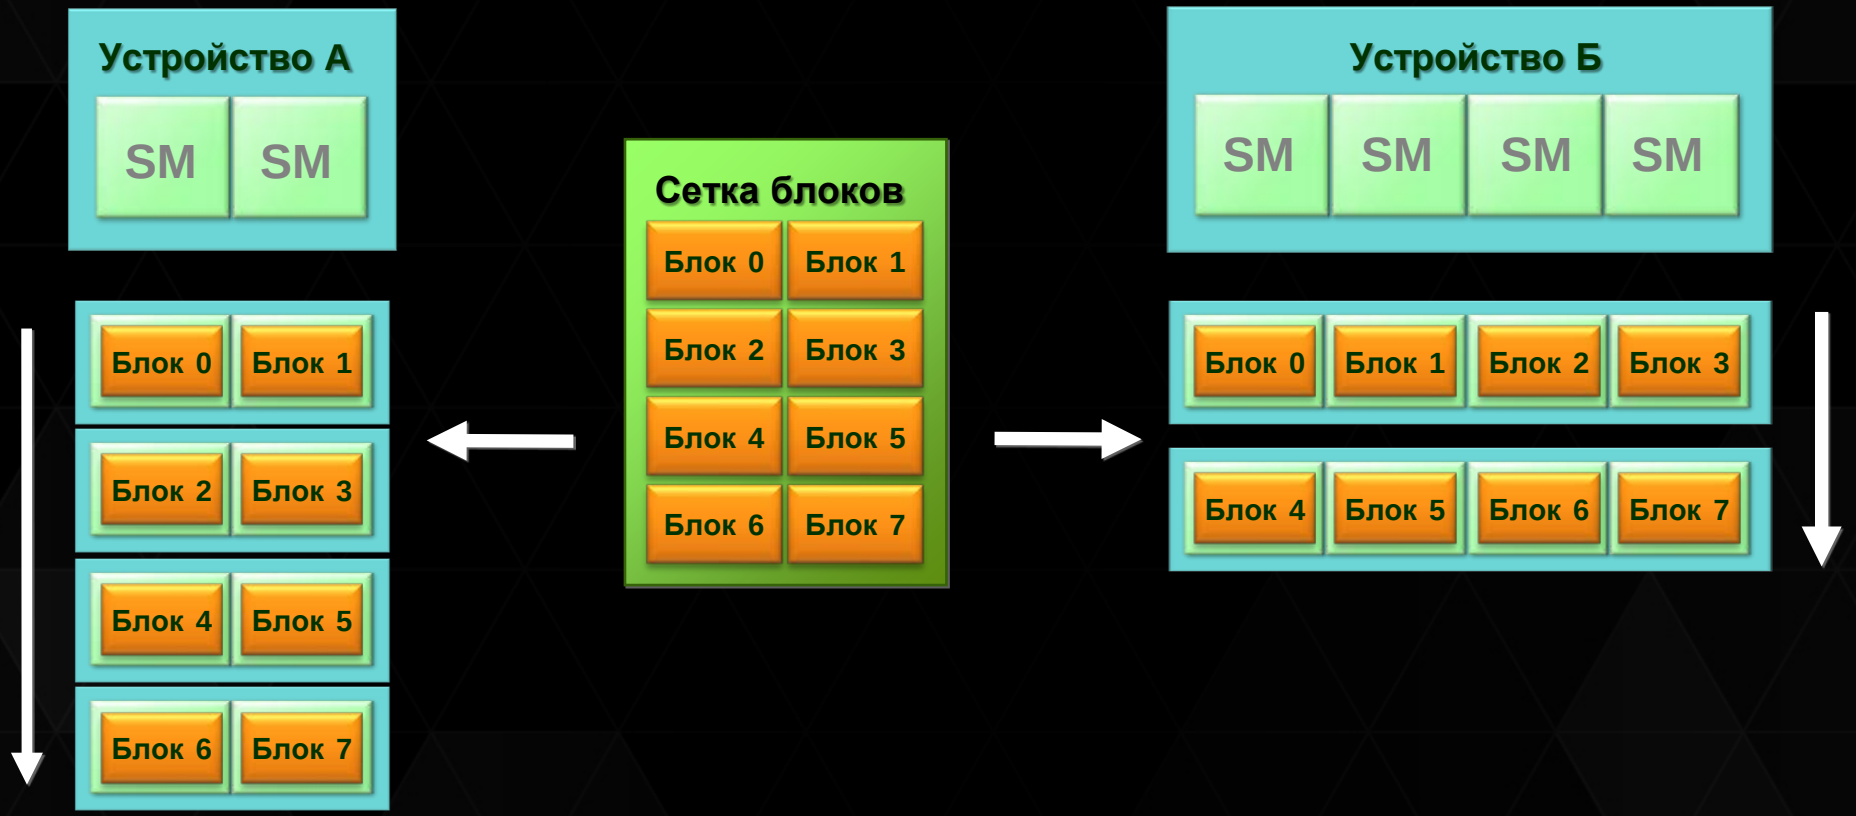

# *Функция-ядро как параллельный код на GPU*

# ФУНКЦИЯ-ЯДРО

```
My_Kernel <<< nBlock, nThread,
              nShMem, nStream >>> ( param )
```

**My_Kernel** – название функции-ядра
**nBlock** – число блоков сети ( grid )
**nThread** – число нитей в блоке
**nShMem** – количество дополнительной разделяемой памяти, выделяемой на блок
**nStream** – номер потока из которого запускается функция ядро

**cudaDeviceSynchronize()** – синхронизация потоков

# ПАРАЛЛЕЛЬНОЕ ВЫПОЛНЕНИЕ КОДА

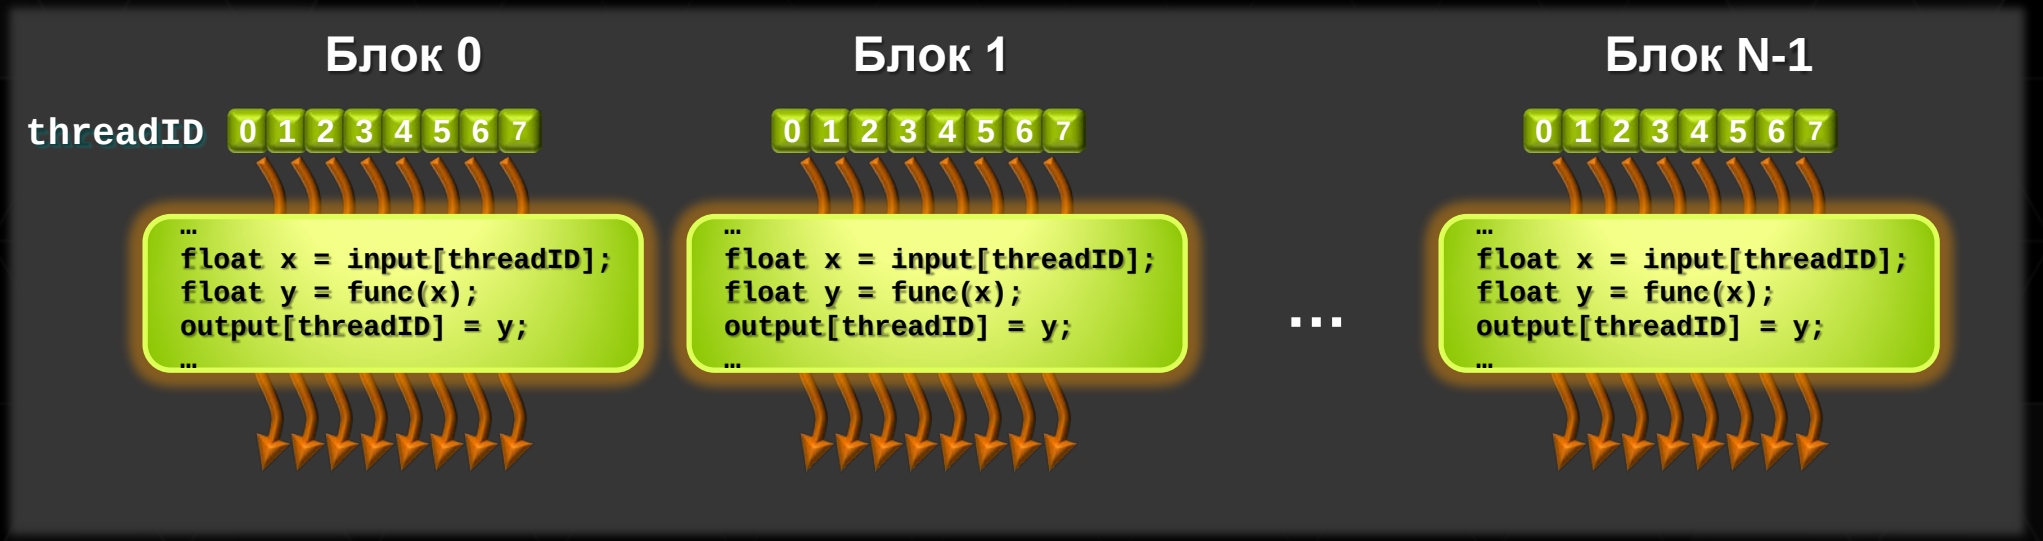

# ВЫПОЛНЕНИЕ НЕСКОЛЬКИХ ФУНКЦИЙ-ЯДЕР

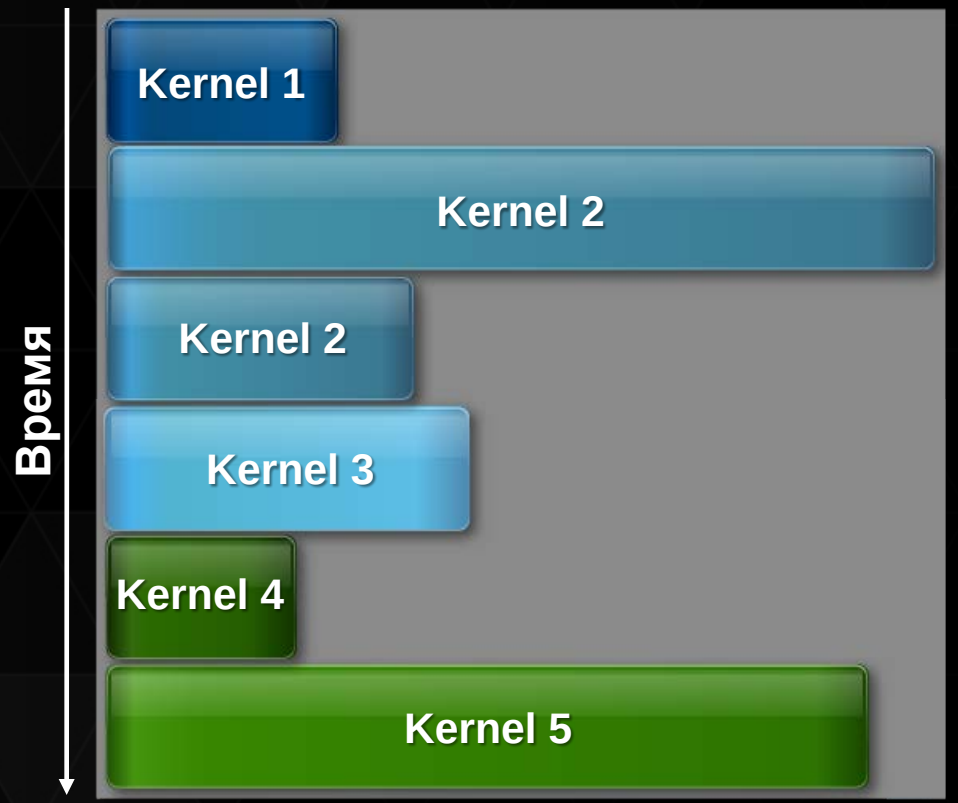


Последовательное исполнение


Параллельное исполнение

Спецификатор функций

| Спецификатор | Выполняется на | Может вызываться из |
|---|---|---|
| __device__ | **device** | **device** |
| __global__ | **device** | **host, device*** |
| __host__ | **host** | **host** |

*только на устройствах с CC 3.5 и выше

Спецификатор переменных

| Спецификатор | Находится | Доступна | Вид доступа |
|---|---|---|---|
| __device__ | device | device/host | R/W |
| __constant__ | device | device/host | R/W |
| __shared__ | device | block | RW<br>__syncthreads() * |
| __managed__ | device | device/host | RW** |
| __restrict__ | - | device/host | RW |

*на версии CUDA 9 возможна синхронизация (кооперация)
отдельной группы нитей внутри блока
**необходим режим UVA

# *Пример программы на CUDA*

# ПРИМЕР

## Параллельного вычисления функции y ( x )

$$y_i = sin(\sqrt{x_i}),\ x_i = \frac{2\pi}{N} i,$$
$$i = 1, \dots, N$$

- N = 1024 * 1024
- 512 нитей в блоке, тогда 2048 блоков
- Массивы dA (device), hA (host)
- cudaMalloc, cudaMemcpy

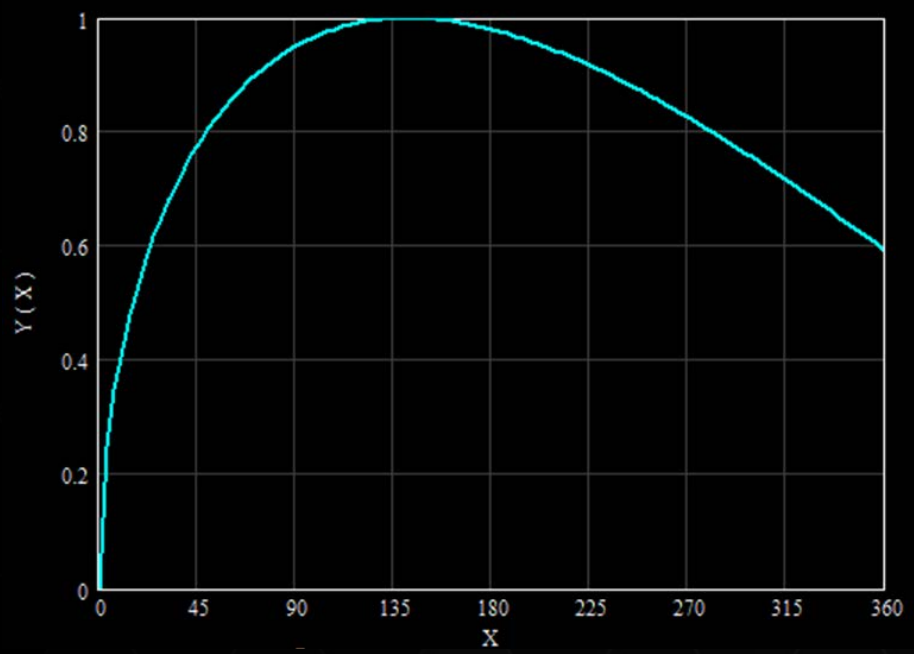

# ПРИМЕР

## Код программы на CUDA ( 1 часть )

```
#include <stdio.h>

#define N (1024*1024)

__global__ void kernel ( float * dA )

{ int idx = blockIdx.x * blockDim.x + threadIdx.x;

  float x = 2.0f * 3.1415926f * (float) idx / (float) N;

  dA [idx] = sinf (sqrtf ( x ) );

}
```

# ПРИМЕР

## Код программы на CUDA ( 2 часть )

```
int main ( int argc, char * argv [] )
{float *hA, *dA;
 hA = ( float* ) malloc (N * sizeof ( float ) );
 cudaMalloc ( (void**)&dA, N * sizeof ( float ) );
 kernel <<< N/512, 512 >>> ( dA );
 cudaMemcpy ( hA, dA, N * sizeof ( float ), cudaMemcpyDeviceToHost );
 for ( int idx = 0; idx < N; idx++ ) printf ( "a[%d] = %.5f\n", idx, hA[idx] );
 free ( hA ); cudaFree ( dA );
 return 0;
}
```

# PARENT AND CHILD GRIDS

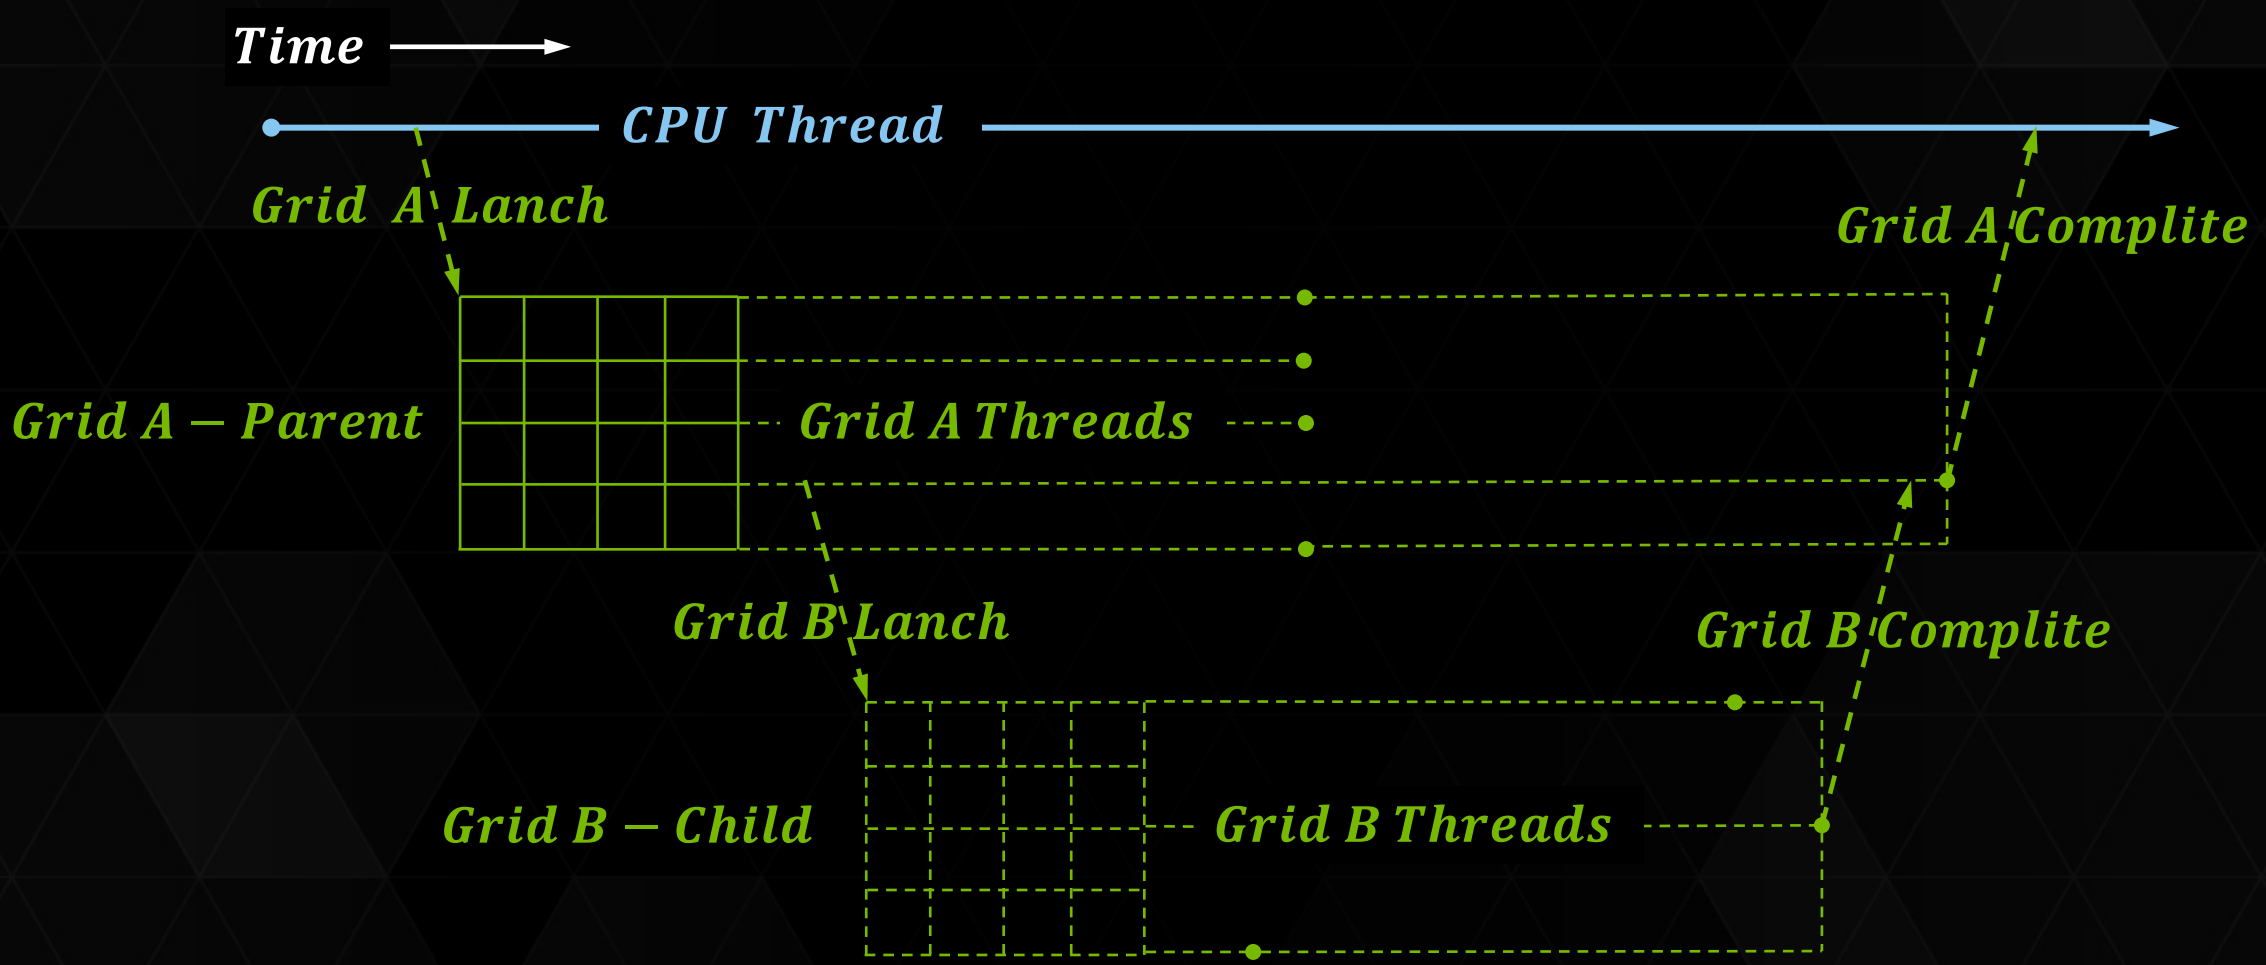

# ПРИМЕР

## Родительская и дочерняя функция-ядро

```
__global__ void child_launch (int *data)
{data[threadIdx.x] = data[threadIdx.x]+1;
}
__global__ void parent_launch (int *data)
{data[threadIdx.x] = threadIdx.x;
 __syncthreads ();
 if (threadIdx.x == 0)
 {child_launch <<< 1, 256 >>> (data);
  cudaDeviceSynchronize ();
 }
 __syncthreads ();
}

void host_launch (int *data)
{parent_launch <<< 1, 256 >>> (data);
}
```

# ОШИБКИ

## Выделения памяти на GPU

```
cudaError_t errMem;
errMem = cudaMalloc ((void**)&dA, N * sizeof ( float ));
if (errMem != cudaSuccess)
{fprintf (stderr, “Cannot allocate GPU memory: %s\n”,
cudaGetErrorString (errMem) );
 return 1;
}
```

# ОШИБКИ

## Копирования данных «host» — «device»

```
cudaError_t errMem;
errMem = cudaMemcpy ( hA, dA, N * sizeof ( float ),
                                        cudaMemcpyDeviceToHost );
if (errMem != cudaSuccess)
{fprintf (stderr, “Cannot copy data device/host : %s\n”,
                                        cudaGetErrorString(errMem) );
 return 1;
}
```

# ОШИБКИ

## Запуска функции-ядра

```
cudaError_t err;
cudaDeviceSynchronize ( );
err = cudaGetLastError ( );
if (err != cudaSuccess)
{fprintf (stderr, “Cannot launch CUDA kernel : %s\n”,
                                    cudaGetErrorString(err) );
 return 1;
}
```

# ОШИБКИ

## Синхронизации

```
cudaError_t errSync;
errSync = cudaDeviceSynchronize ( );
if (errSync != cudaSuccess)
{ fprintf (stderr, “Cannot synchronize CUDA kernel : %s\n”,
                                    cudaGetErrorString(errSync) );
  return 1;
}
```